一篇搞明白！MCP、RAG、Agent

> *MCP、RAG、Agent 这些概念最近热度飙升，为了帮助大家更好地理解，精心绘制了 12 张简单易懂的架构图解。这些架构图解涵盖了从 MCP 的提示词混合机制，到 RAG 的知识检索增强，再到 Agent 的自主决策框架等多个方面。*

一、MCP、RAG、Agent 概念与关系

第一、核心概念

1、RAG（检索增强生成）

✍️ **定义**：RAG 将信息检索与文本生成相结合，创造更准确、信息更充分的回应。

功能：从知识库中检索相关文档，并用它们增强生成过程。

主要优势：使 AI 回应建立在事实信息基础上，减少幻觉（hallucinations）。

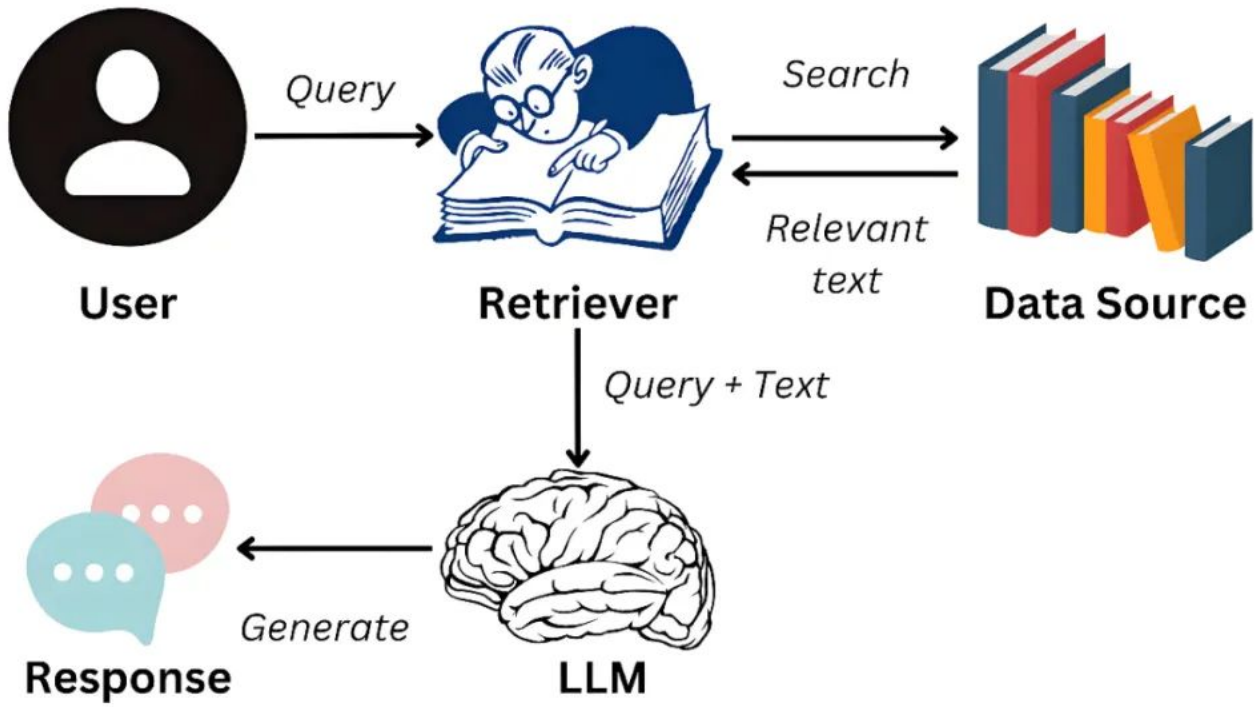

组成部分：

- 知识库：存储大量文档和数据。
- 检索组件：包括嵌入模型和向量数据库，用于高效检索相关文档。

- 生成模型：基于语言模型，生成最终的文本回应。

2、Agent（智能体）

✍️ **定义**：一种能够感知、决策和行动以实现特定目标的自主 AI 系统。

功能：基于观察和目标在环境中采取行动。

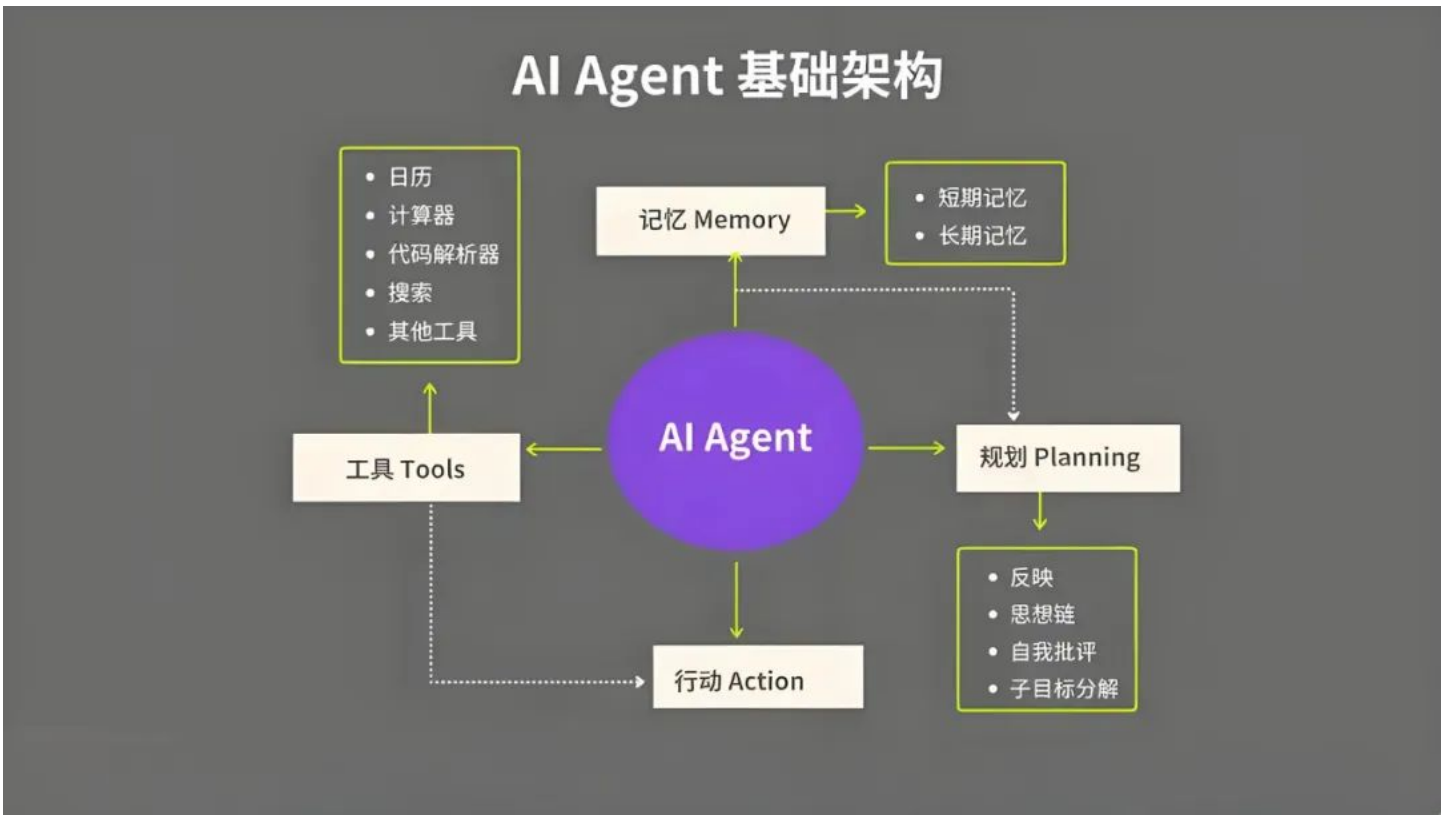

核心组件：

- 感知模块：用于感知环境状态。
- 推理/决策模块：基于感知信息进行推理和决策。
- 工具使用能力：调用外部工具和资源以完成任务。

例子：

- 客户服务智能体
- 数据分析智能体
- 复杂任务处理智能体

3、MCP（模型上下文协议）

✍️ **定义**：一种连接 AI 助手与外部系统的开放标准，使模型能够获取上下文信息。

功能：实现 AI 模型与外部数据源和工具的标准化通信。

主要优势：提供统一接口，简化 AI 与各类系统的集成。

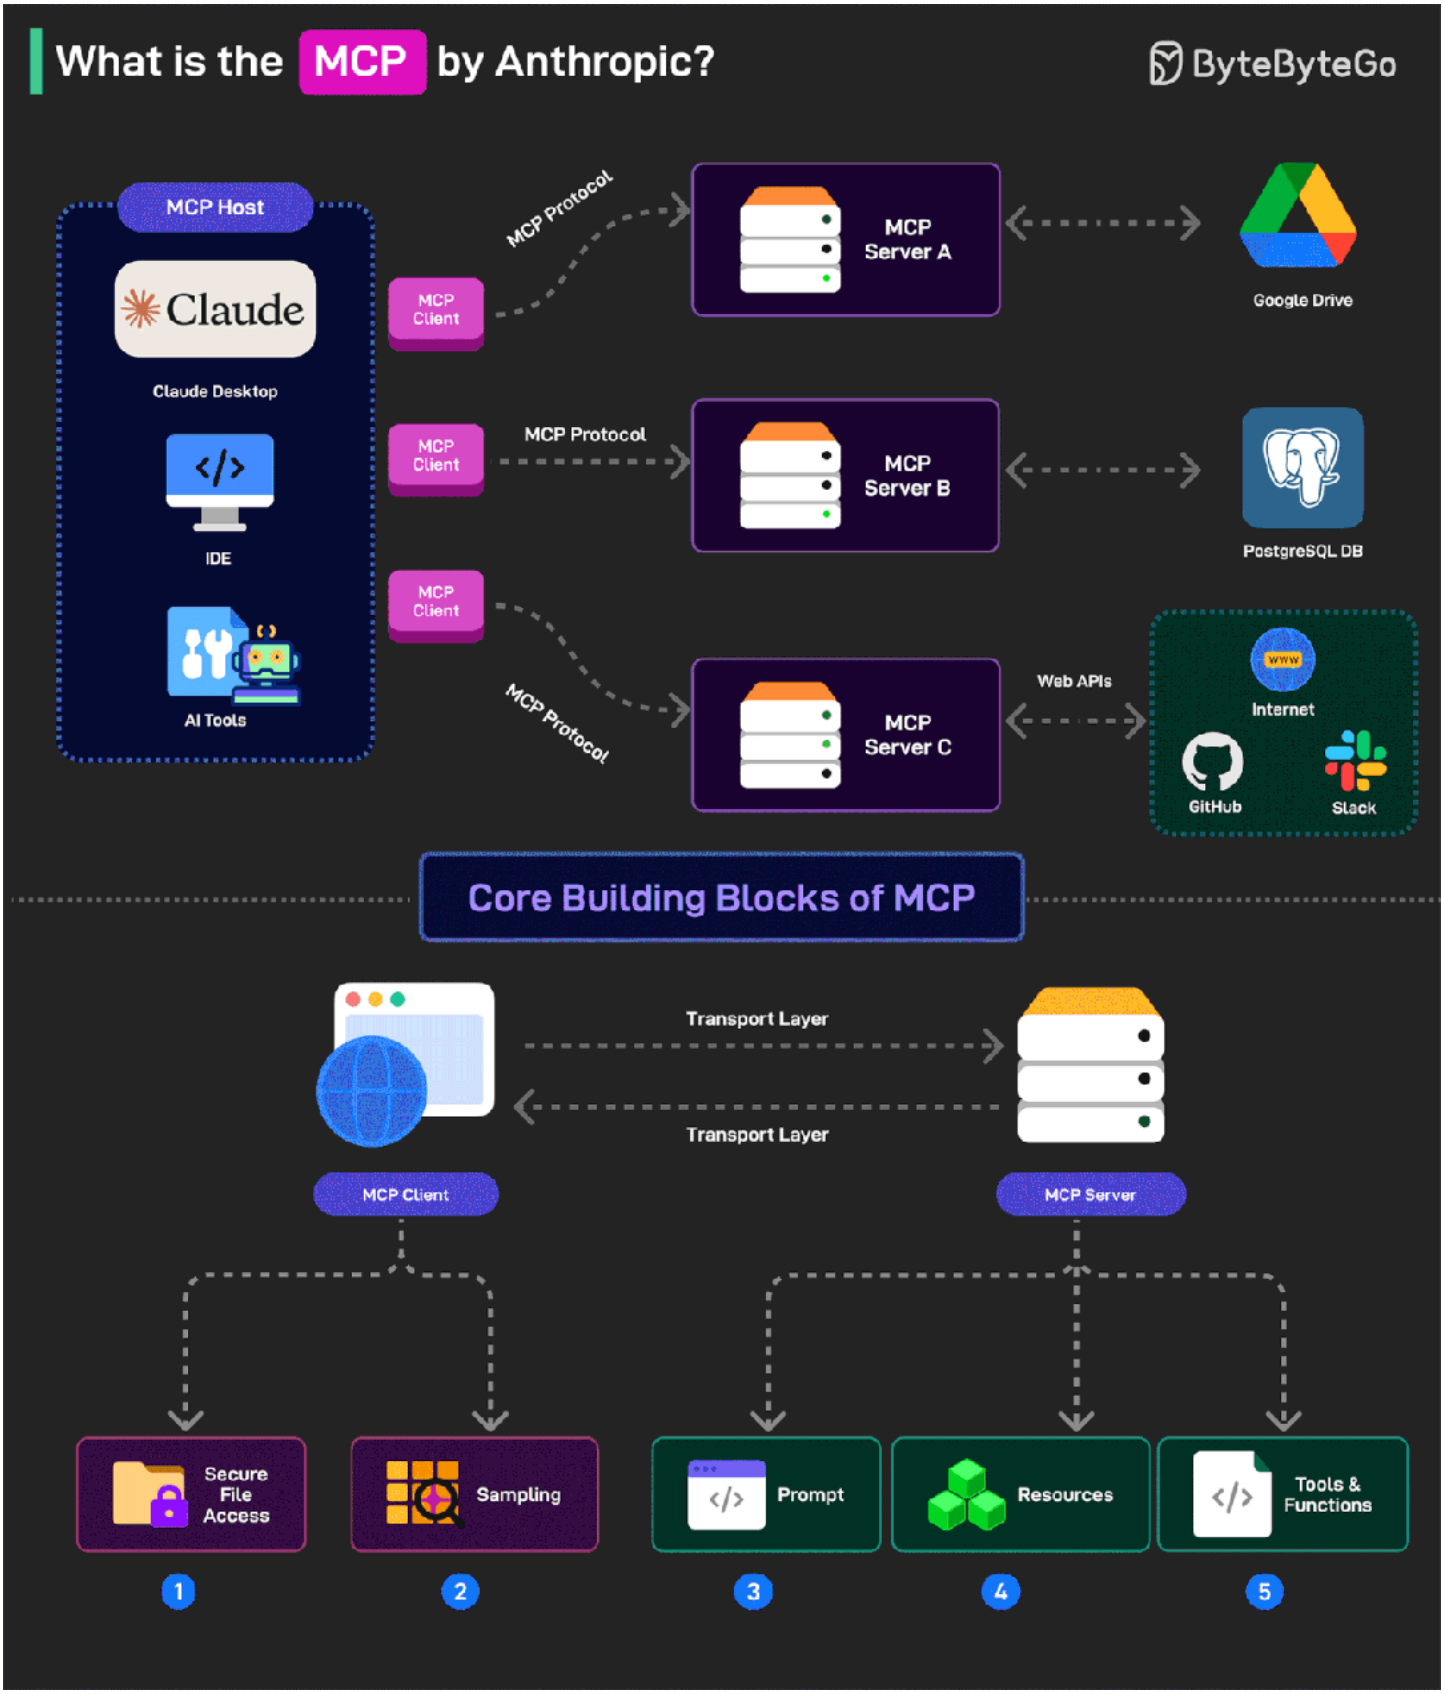

组成部分：

- 客户端-服务器架构：支持多个客户端与服务器之间的通信。
- 标准化通信协议：确保不同系统之间的兼容性。
- 工具调用接口：允许 AI 模型调用外部工具和资源。

第二、核心概念之间的关系

1、RAG ↔ Agent 之间关系

- RAG 作为 Agent 的知识组件。
- RAG 常作为智能体（Agent）内的知识组件，为决策提供事实基础。
- Agent 利用 RAG 访问相关信息，从而做出更明智的决策。

当 RAG 与 Agent 结合使用（即 Agentic RAG）时，Agent 的决策能力和 RAG 的知识能力相互增强，提升整体性能。

2、Agent ↔ MCP 之间关系

- MCP 作为 Agent 的外部交互接口。
- MCP 为 Agent 提供与外部系统交互的标准化接口。
- Agent 可以通过 MCP 调用工具、获取数据，从而扩展其行动能力。
- MCP 简化了 Agent 与多种外部服务的集成，显著提高了开发效率。

3、MCP ↔ RAG 之间关系

- MCP 作为 RAG 的外部知识通道。
- MCP 可以作为 RAG 系统获取外部知识的通道。
- 通过 MCP 连接的数据源可以丰富 RAG 的知识库。
- MCP 标准化了 RAG 系统访问各类数据仓库的方式，确保数据的一致性和可访问性。

4、实际实现

在一个完整的 AI 系统中，这些元素协同工作，实现高效、智能的任务处理：

- Agent 通过 MCP 与外部系统建立连接：Agent 利用 MCP 提供的标准化接口，与外部数据源和工具进行交互。
- Agent 使用 RAG 检索并整合相关知识：Agent 通过 RAG 访问知识库，检索与任务相关的事实信息，为决策提供支持。
- 系统结合决策能力和事实信息处理复杂任务：Agent 将检索到的知识与自身的决策能力相结合，处理复杂的任务，生成准确、可靠的回应。

这种整合方法创造出比任何单一组件都更强大、更可靠、更适应性强的 AI 系统，能够理解上下文，检索相关信息，并采取适当行动完成任务。

第三、生活案例

- **RAG 像一个认真的学生**： 想象一个学生写论文。遇到不懂的内容，他不会瞎编，而是去图书馆查找资料，找到相关书籍，然后基于这些可靠信息来写论文。RAG 就是 AI 的“查资料”能力。
- **Agent 像一个私人助理**： 假设你告诉助理：“帮我安排下周去北京的商务旅行。”一个好助理会自己决定需要预订机票、酒店、安排会议时间等，并自己完成这些任务。Agent 就是 AI 的这种“理解目标并自主行动”的能力。
- **MCP 像一个万能转接头**： 你可能有过这种经历：带着国内的充电器去国外，发现插不进插座。这时你需要一个转接头。MCP 就是 AI 的“转接头”，让 AI 能够连接和使用各种外部工具和数据源。

1、想想你自己如何完成一项复杂任务

- **你需要知识（类似 RAG）**：在做任何事情之前，你都需要获取相关的信息和知识。
- **你需要决策能力（类似 Agent）**：有了知识后，你需要根据这些信息做出决策和规划。
- **你需要使用工具的能力（类似 MCP）**：最后，你需要使用各种工具来执行这些决策。

> 例如，烹饪一道新菜：你会查菜谱（RAG），根据实际情况调整做法（Agent），使用各种厨具（通过 MCP 连接）。

2、启发思考

- **如果 AI 只有 RAG 能力（只会查资料），但不会思考和使用工具**：它可以回答一些基于事实的问题，但无法完成复杂的任务。例如，它可以告诉你昨天的股市情况，但无法帮你制定投资策略。
- **如果 AI 只能思考决策（Agent），但没有可靠的信息来源（RAG）**：它可能会做出一些基于假设的决策，但这些决策可能不准确。例如，它可以帮你策划旅行，但可能会忽略一些重要的细节。
- **没有标准接口（MCP），每个工具都需要特殊连接方式**：这会给 AI 使用工具带来巨大的挑战，增加开发和维护的复杂性。例如，每次需要使用一个新的工具，都需要重新编写代码来适配。

你能想象这三种能力完美结合的 AI 能帮你完成什么任务吗？

3、你有一个超级智能助手。这个助手有三种超能力

- **超级记忆（RAG）**：不管你问什么，它都能迅速查找到准确的信息，而不是凭空想象或编造答案。比如你问“昨天的股市怎么样”，它会立刻找出真实数据告诉你。
- **独立思考（Agent）**：你只需告诉它你想要什么结果，它就能自己思考并决定如何一步步实现。比如你说“帮我策划一次旅行”，它会自动考虑预算、时间、景点等因素并给出完整计划。
- **万能连接器（MCP）**：它能够使用各种外部工具和系统。需要发邮件？预订机票？计算复杂数学问题？它都能连接到适当的工具来完成。

当这三种能力结合在一起，你就拥有了一个既知识丰富，又能独立思考，还能使用各种工具的全能助手。这就是现代 AI 系统通过结合 RAG、Agent 和 MCP 所追求的目标。

二、MCP、RAG、Agent 架构设计图解

第一、9张架构设计概念图解!

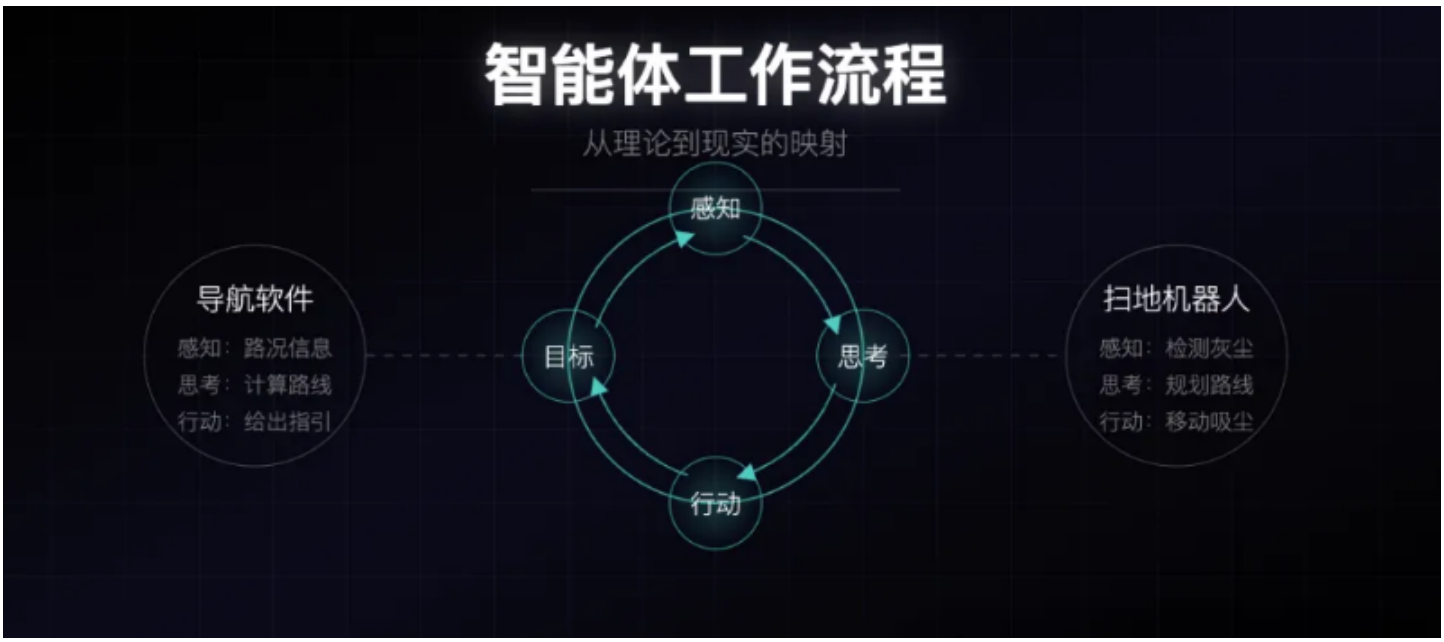

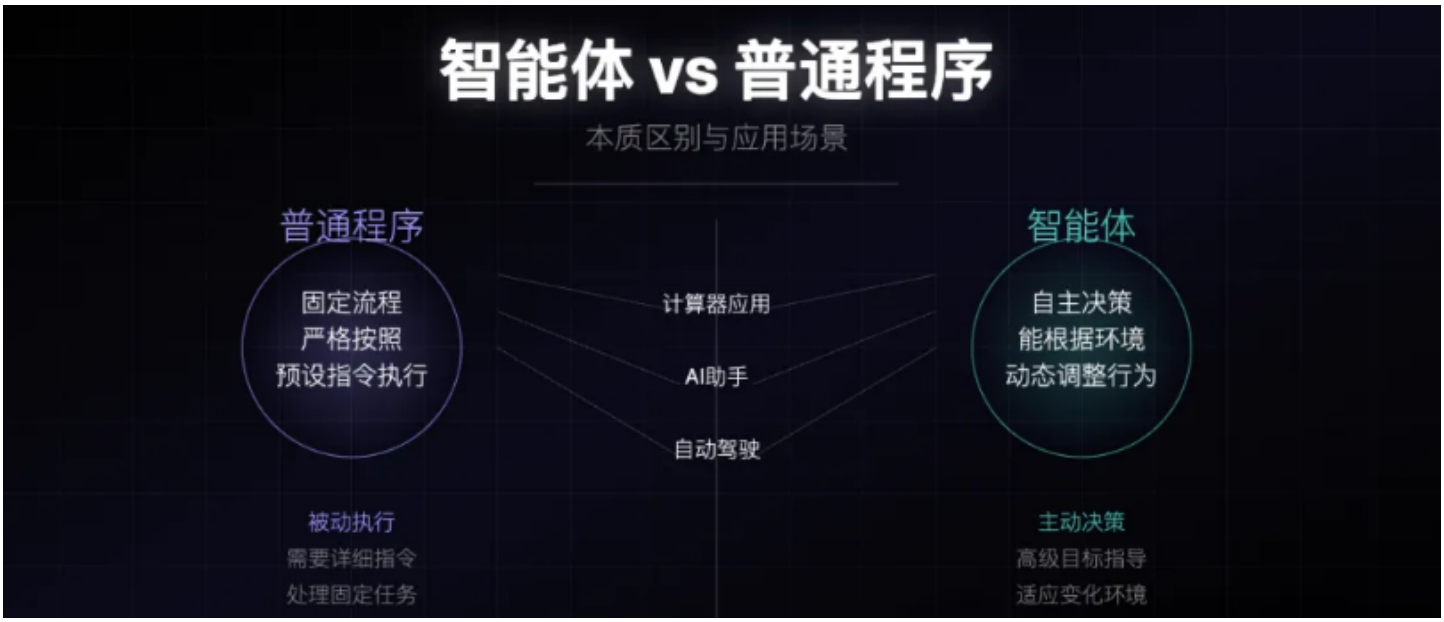
智能体 vs 普通程序
本质区别与应用场景
普通程序
固定流程
严格按照
预设指令执行
计算器应用
AI助手
自动驾驶
智能体
自主决策
能根据环境
动态调整行为
被动执行
需要详细指令
处理固定任务
主动决策
高级目标指导
适应变化环境

RAG
检索增强生成
Retrieval-Augmented Generation
先查找外部信息
再基于信息生成回答
检索
查找外部信息
增强
结合外部信息
生成
创建回答内容

RAG工作流程
如何结合外部知识生成回答
用户问题
检索知识
知识增强
生成回答
外部知识库
厨师烹饪类比
日常类比:
顾客点菜→查食谱→结合经验→制作呈现

对比分析
传统生成 vs 检索增强生成
传统生成
仅依赖
训练数据
中的知识
信息可能过时
知识范围有限
细节准确性受限
检索增强生成
结合外部
最新知识
生成回答
信息更新更准确
知识范围更广
细节更丰富

Model Context Protocol
费曼解释 · AI的通用连接标准
让AI与外部世界
无缝连接的
通用协议
Host
宿主
(如Claude界面)
Client
客户端
(管理连接)
Server
服务器
(提供功能)

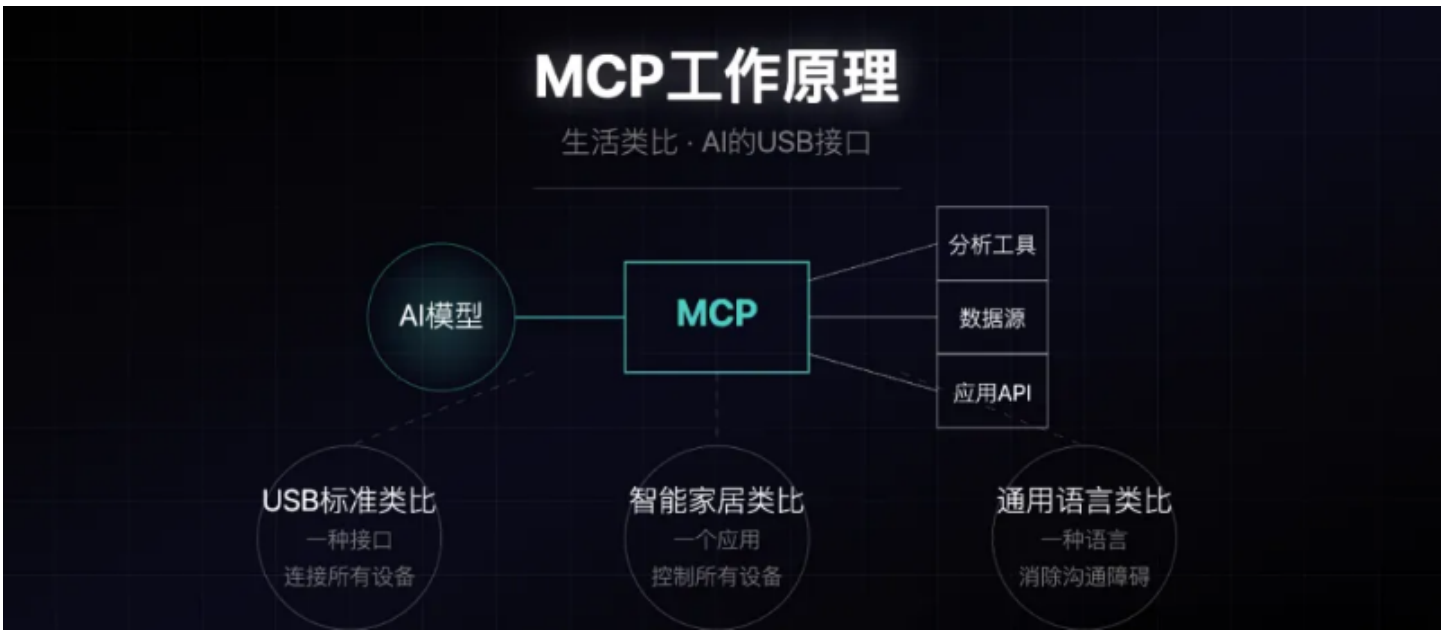
MCP工作原理
生活类比 · AI的USB接口
AI模型
MCP
分析工具
数据源
应用API
USB标准类比
一种接口
连接所有设备
智能家居类比
一个应用
控制所有设备
通用语言类比
一种语言
消除沟通障碍

第二、3张架构设计关系图解

工作机制详解
RAG
查询处理
检索相关信息
合成回答
向量数据库
嵌入模型
信息索引
减少幻觉，提高准确性
Agent
理解目标
规划步骤
执行行动
结果评估
自主思考
策略制定
反馈调整
能解决复杂任务，自主决策
MCP
识别需要的工具
建立连接
交换数据
整合结果
标准接口
数据转换
跨系统通信
扩展AI能力，连接外部世界

协同工作系统
用户需求
1. 检索相关信息
知识库
RAG
决策系统
Agent
2. 规划执行策略
AI大模型
协调三大能力
MCP
3. 调用外部工具
计算工具
数据源
API接口