基准测试（Benchmark）

LLM（Large Language Model，大型语言模型）中的Benchmark（基准测试）是用于衡量和比较不同LLM性能的一组经过精心设计的测试任务、问题和数据集。这些基准测试遵循标准化的流程，以评估LLM在核心语言处理任务上的表现。

Model / Benchmark	GSM8K (May 2021)	HumanEval (Jul 2021)	MBPP (Aug 2021)	MultiPL-E (Aug 2022)	DS-1000 (Nov 2022)	AgentBench (August 2023)	RepoBench (October 2023)	SWE-Bench (October 2023)
GPT-3.5 (Mar 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
GPT-4 (Mar 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
StarCoder (May 2023)	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was evaluated before	was evaluated before	was evaluated before
PaLM 2 (May 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
WizardCoder (Jun 2023)	was not evaluated on	was evaluated on	was evaluated on	was not evaluated on	was evaluated on	was evaluated before	was evaluated before	was evaluated before
Claude 2 (Jul 2023)	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Llama 2 (July 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Code Llama (Aug 2023)	was evaluated on	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was evaluated before	was evaluated before	was evaluated before
Mistral (Sep 2023)	was evaluated on	was evaluated on	was evaluated on	was not evaluated on	was not evaluated on	was not evaluated on	was evaluated before	was evaluated before

一、Benchmark

1. 什么是基准测试（Benchmark）？

评估AI系统或模型性能的一种标准化测试方法。它通过使用预定义的数据集、任务和评估指标，对AI模型在特定任务上的表现进行量化评估，以便比较不同模型之间的性能差异。

1. 标准化评估：提供一套标准化的测试流程和评估指标，确保不同模型之间的比较具有公平性和一致性。 **2. 性能比较**：帮助研究人员和开发者了解不同AI模型在同一任务上的性能差异，从而选择最适合的模型。 **3. 技术进步追踪**：通过定期更新基准测试，追踪AI技术随时间的进步和发展。

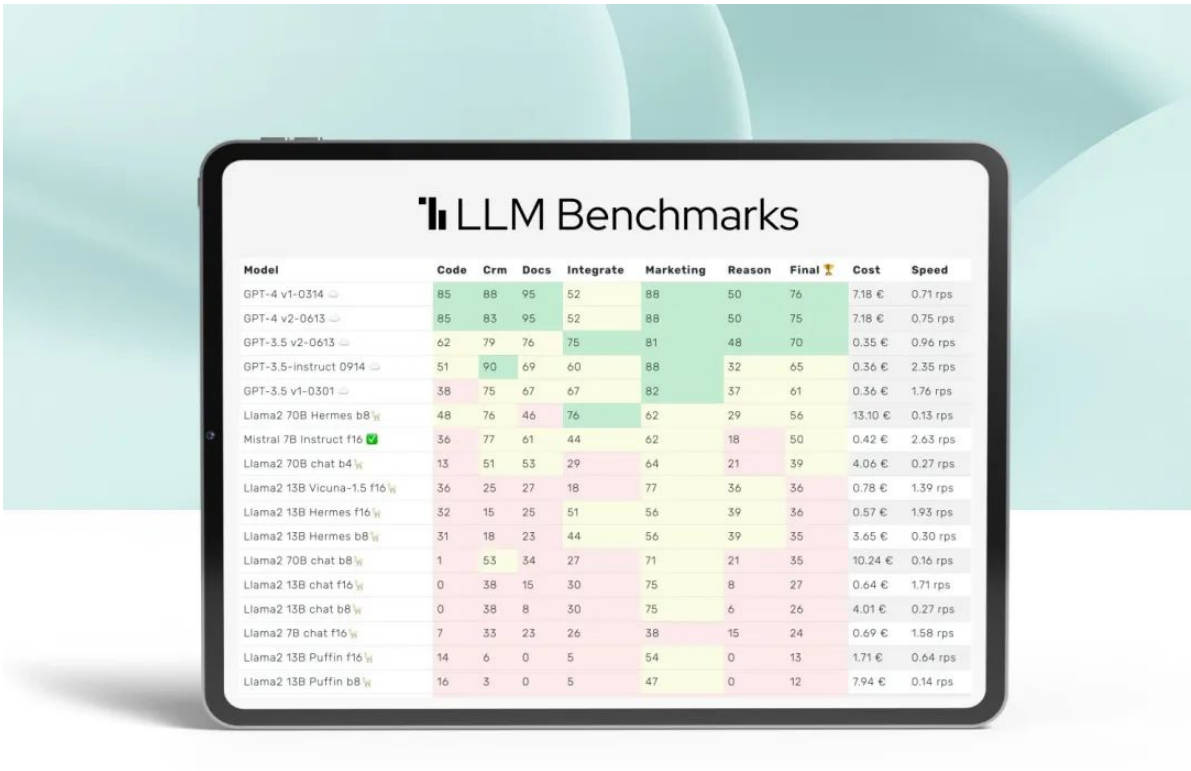

LLM Benchmarks

Model	Code	Crm	Docs	Integrate	Marketing	Reason	Final	Cost	Speed
GPT-4 v1-0314	85	88	95	52	88	50	76	7.18 €	0.71 rps
GPT-4 v2-0613	85	83	95	52	88	50	75	7.18 €	0.75 rps
GPT-3.5 v2-0613	62	79	76	75	81	48	70	0.35 €	0.96 rps
GPT-3.5-instruct 0914	51	90	69	60	88	32	65	0.36 €	2.35 rps
GPT-3.5 v1-0301	38	75	67	67	82	37	61	0.36 €	1.76 rps
Llama2 70B Hermes b8	48	76	46	76	62	29	56	13.10 €	0.13 rps
Mistral 7B Instruct f16	36	77	61	44	62	18	50	0.42 €	2.63 rps
Llama2 70B chat b4	13	51	53	29	64	21	39	4.06 €	0.27 rps
Llama2 13B Vicuna-1.5 f16	36	25	27	18	77	36	36	0.78 €	1.39 rps
Llama2 13B Hermes f16	32	15	25	51	56	39	36	0.57 €	1.93 rps
Llama2 13B Hermes b8	31	18	23	44	56	39	35	3.65 €	0.30 rps
Llama2 70B chat b8	1	53	34	27	71	21	35	10.24 €	0.16 rps
Llama2 13B chat f16	0	38	15	30	75	8	27	0.64 €	1.71 rps
Llama2 13B chat b8	0	38	8	30	75	6	26	4.01 €	0.27 rps
Llama2 7B chat f16	7	33	23	26	38	15	24	0.69 €	1.58 rps
Llama2 13B Puffin f16	14	6	0	5	54	0	13	1.71 €	0.64 rps
Llama2 13B Puffin b8	16	3	0	5	47	0	12	7.94 €	0.14 rps

2. 基准测试（Benchmark）的核心要素是什么?

使用公开认可的数据集，定义具体任务，并通过适当的评估指标全面评估AI模型在不同领域的性能。

1. 数据集：使用公开、广泛认可的数据集，这些数据集通常包含多种类型的任务和场景，以全面评估AI模型的性能。 **2. 任务**：定义一系列具体的任务，如文本分类、图像识别、语音识别等，以测试AI模型在不同领域的应用能力。 **3. 评估指标**：选择适当的评估指标来衡量AI模型的性能，如准确率、召回率、F1值、延迟、能耗等。

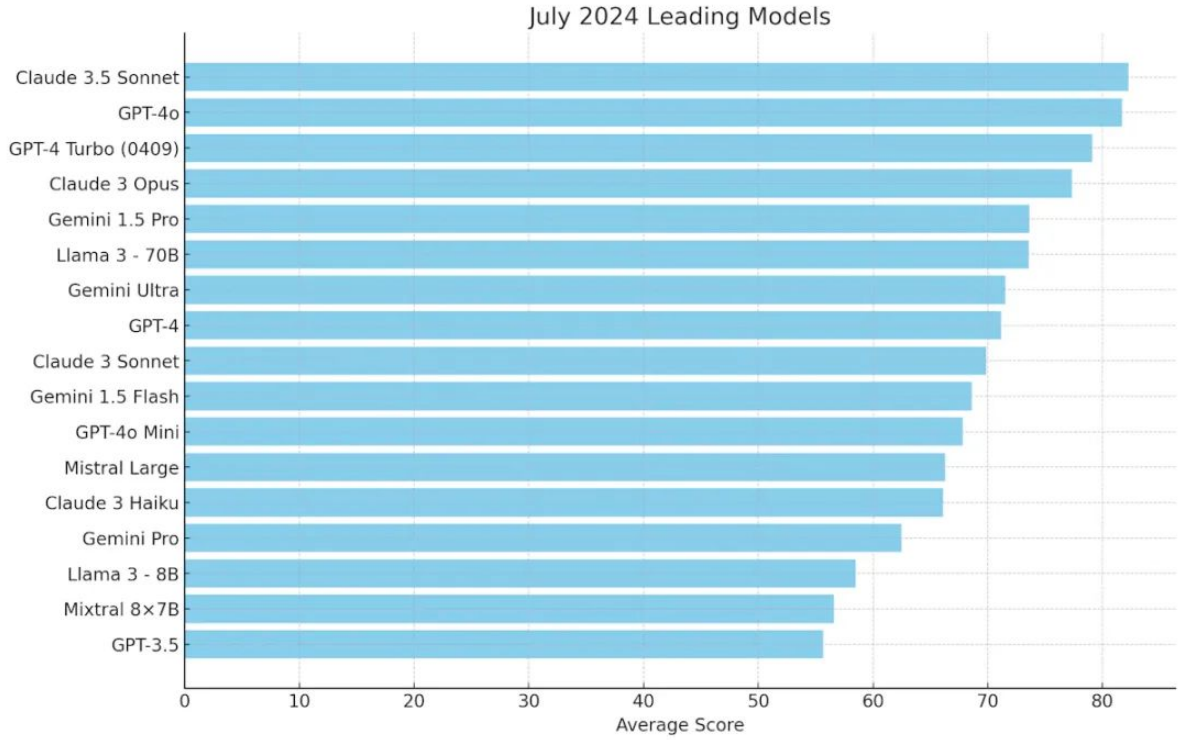

二、NLP的Benchmark

1. 什么是NLP（自然语言处理）？

NLP使用了统计学、机器学习、深度学习等多种技术，通过处理大量的文本数据和语言规则，从而提取出语义、情感、信息等。

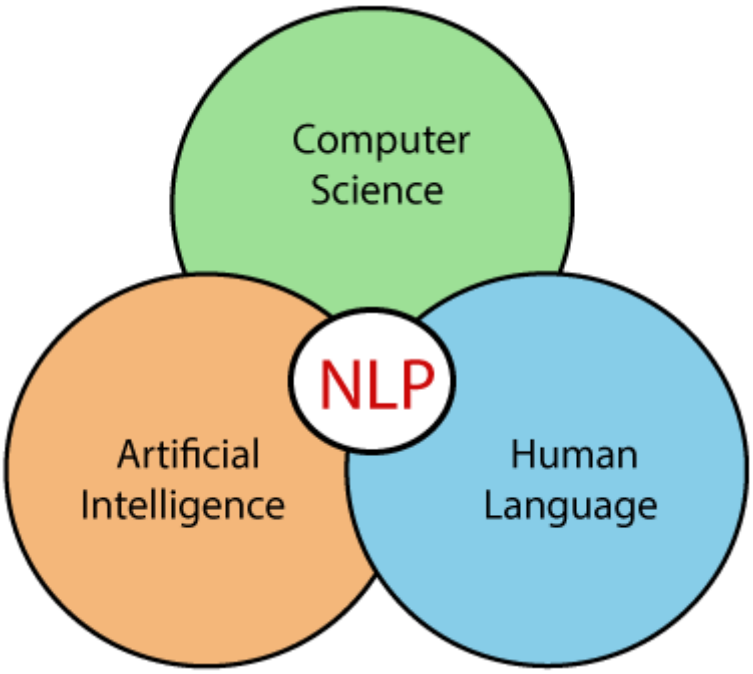

NLP旨在使计算机能够识别、理解、解释和生成人类语言，从而实现与人类进行自然而智能的交互。

- **文本分类：** 将文本数据自动分类到预定义的类别中。
- **语义理解：** 理解文本的含义和上下文关系。
- **语言生成：** 根据输入生成自然语言文本。
- **机器翻译：** 将一种语言的文本自动翻译成另一种语言。
- **语音识别：** 将人类语音转换为文本。
- **问答系统：** 回答用户提出的问题。

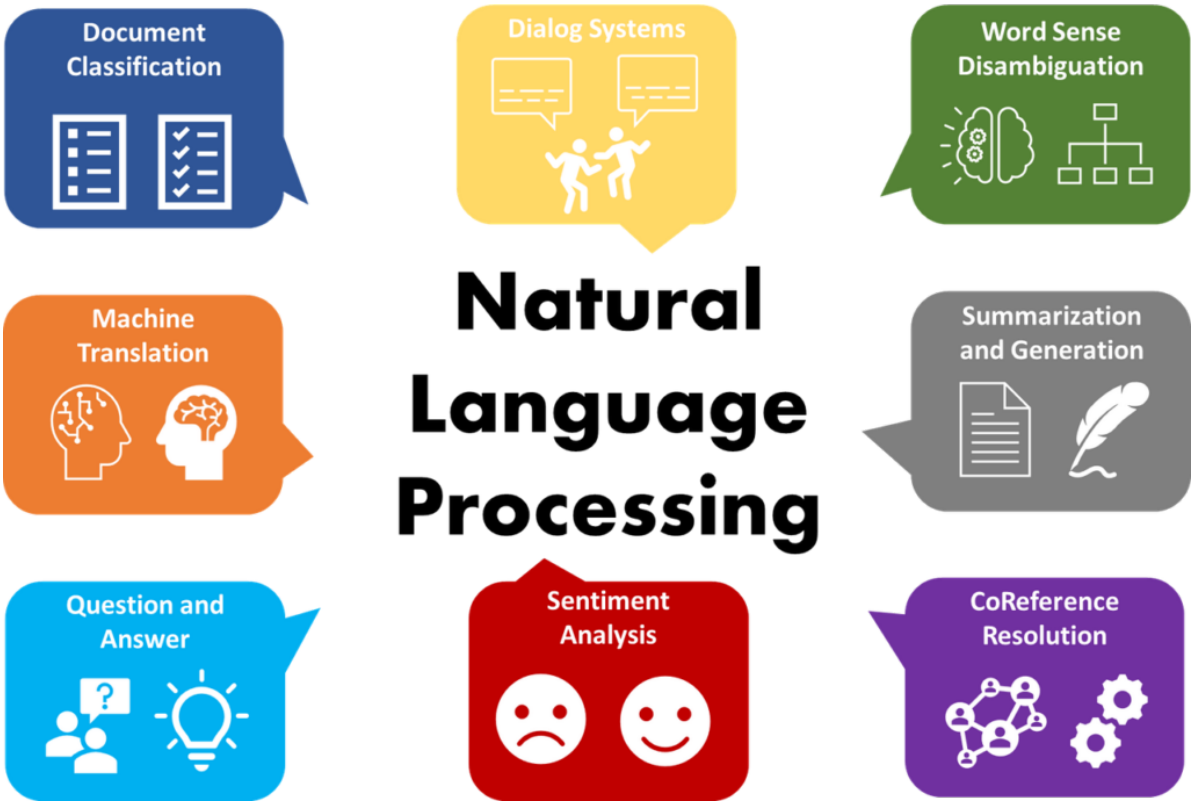

2. 自然语言处理（NLP）基准测试：

如GLUE、SuperGLUE、SQuAD等，用于评估AI模型在自然语言理解方面的能力。

1. GLUE（General Language Understanding Evaluation）

GLUE是由纽约大学和斯坦福大学联合发起的自然语言理解基准测试平台，旨在推动研究者对广泛的任务进行深度学习模型的评估和比较。

GLUE任务涵盖了词汇水平、句子水平和篇章级别的理解和推理。 GLUE包含9个不同的自然语言理解任务，如句子对分类（MRPC）、情感分析（SST-2）、问答一致性评估（QNLI）、同义词替换检测（STS-B）等。

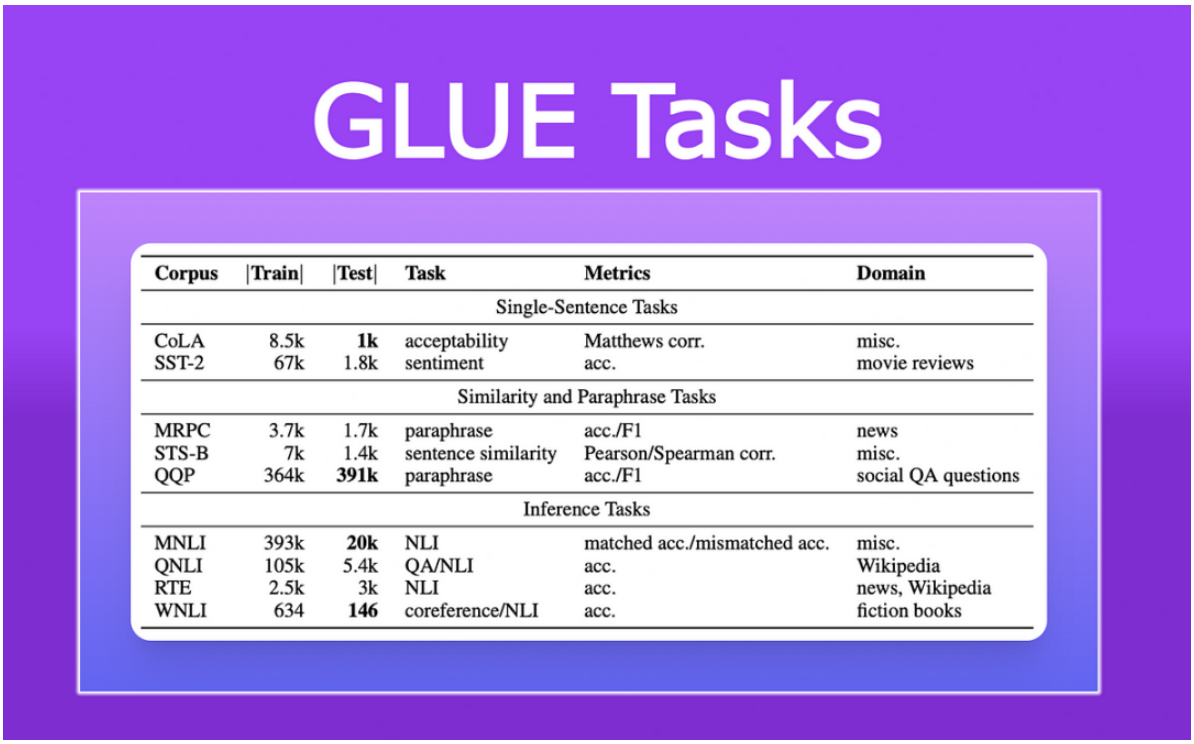

Corpus	|Train|	|Test|	Task	Metrics	Domain
Single-Sentence Tasks					
CoLA	8.5k	**1k**	acceptability	Matthews corr.	misc.
SST-2	67k	1.8k	sentiment	acc.	movie reviews
Similarity and Paraphrase Tasks					
MRPC	3.7k	1.7k	paraphrase	acc./F1	news
STS-B	7k	1.4k	sentence similarity	Pearson/Spearman corr.	misc.
QQP	364k	**391k**	paraphrase	acc./F1	social QA questions
Inference Tasks					
MNLI	393k	**20k**	NLI	matched acc./mismatched acc.	misc.
QNLI	105k	5.4k	QA/NLI	acc.	Wikipedia
RTE	2.5k	3k	NLI	acc.	news, Wikipedia
WNLI	634	**146**	coreference/NLI	acc.	fiction books

2. SuperGLUE（Super General Language Understanding Evaluation）

SuperGLUE是在GLUE基础上推出的一个更加全面和具有挑战性的评估平台，旨在推动NLP领域的发展。它由纽约大学、华盛顿大学、DeepSeek、艾伦人工智能研究所和Facebook AI Research共同开发。

SuperGLUE包含了一系列新的更困难的语言理解任务，如BoolQ（基于阅读理解的是非题）、CommitmentBank（判断句子与段落信息的一致性）、MultiRC（多选题阅读理解）等。这些任务涵盖了语言理解的不同方面，包括阅读理解、常识推理、代词消歧等。

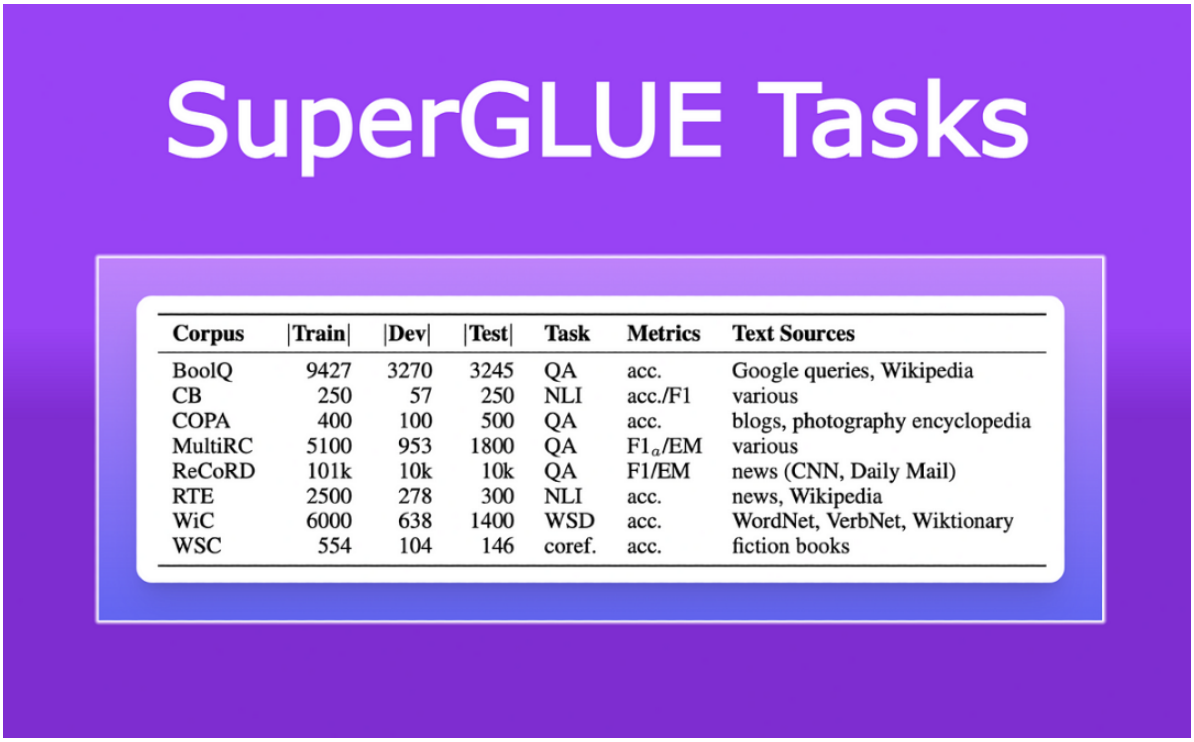

Corpus	|Train|	|Dev|	|Test|	Task	Metrics	Text Sources
BoolQ	9427	3270	3245	QA	acc.	Google queries, Wikipedia
CB	250	57	250	NLI	acc./F1	various
COPA	400	100	500	QA	acc.	blogs, photography encyclopedia
MultiRC	5100	953	1800	QA	$F1_a$/EM	various
ReCoRD	101k	10k	10k	QA	F1/EM	news (CNN, Daily Mail)
RTE	2500	278	300	NLI	acc.	news, Wikipedia
WiC	6000	638	1400	WSD	acc.	WordNet, VerbNet, Wiktionary
WSC	554	104	146	coref.	acc.	fiction books

3. SQuAD（Stanford Question Answering Dataset）

SQuAD是斯坦福大学于2016年推出的一个阅读理解数据集，用于评估算法从文章中找出问题答案的能力。

- **大规模**：数据集包含107,785个问题以及配套的536篇文章，所有文章均选自维基百科。
- **广泛应用**：由于其数据量和质量的优势，SQuAD已成为评估阅读理解模型性能的重要基准之一。

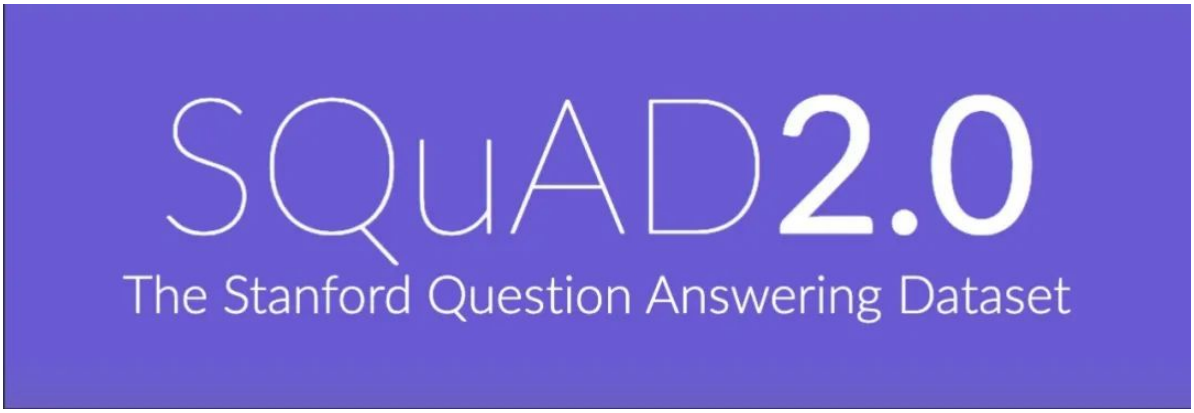

SQuAD广泛应用于各种NLP任务中，特别是阅读理解任务。通过在该数据集上的表现，可以评估模型在理解文本、提取关键信息以及生成答案等方面的能力。

18 Jan 05, 2019	synss (single model) *bert_finetune*	76.055	79.329
19 Dec 18, 2018	ARSG-BERT (single model) *TRINITI RESEARCH LABS, Active.ai* https://active.ai	74.746	78.227
19 Nov 05, 2018	MIR-MRC(F-Net) (single model) *Kangwon National University, Natural Language Processing Lab. & ForceWin, KP Lab.*	74.791	77.988
20 Sep 13, 2018	nlnet (single model) *Microsoft Research Asia*	74.272	77.052

三、CV的Benchmark

1. 什么是CV（计算机视觉）？

计算机视觉（Computer Vision, CV）是指计算机利用摄像机、图像传感器等设备获取图像或视频，并通过复杂的算法对这些图像或视频进行处理和分析，以实现对图像或视频中的物体、场景以及其属性的理解和识别的技术领域。

- **图像处理**：对图像进行预处理、增强、恢复、变换等操作，以提高图像的质量和可用性。
- **目标检测与识别**：能够识别和分类图像中的物体、场景或者特定的图案。例如，面部识别、物体识别等。
- **视频分析**：对视频进行分析和处理，包括视频监控、运动检测、人脸识别等。

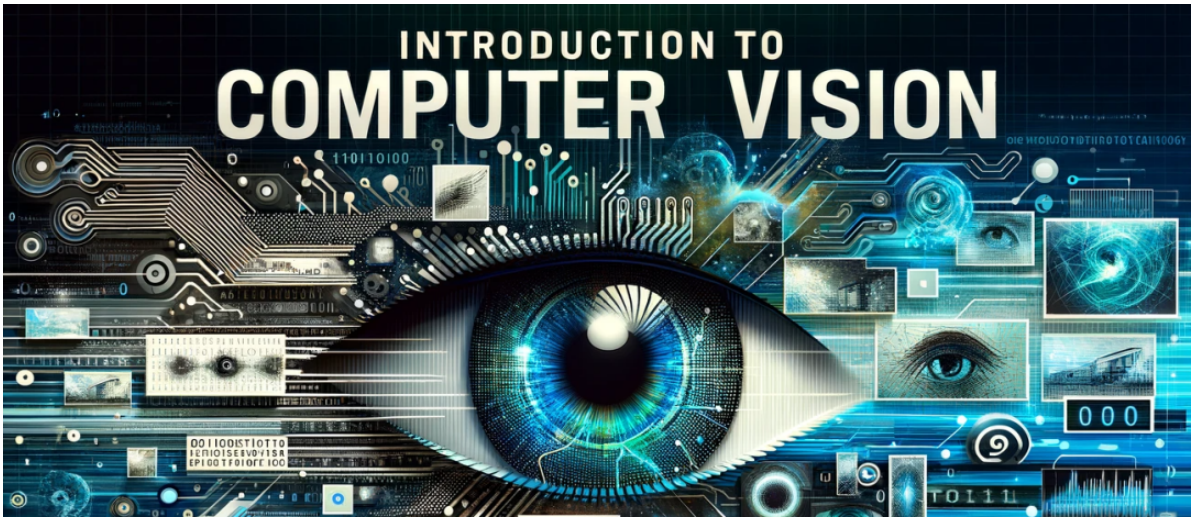

2. 计算机视觉（CV）基准测试：

如ImageNet、COCO等，用于评估AI模型在图像分类、目标检测等任务上的性能。

1）ImageNet

ImageNet是一个由斯坦福大学李飞飞等人创建的大规模图像数据库，它包含了超过1400万张样例图片，这些图片被分为27个大类和超过2万个小类。ImageNet因其庞大的规模和丰富的类别而成为计算机视觉领域的重要资源。

1. 计算机视觉研究和开发：ImageNet提供了一个大规模的图像数据库，可用于训练和评估图像分类、目标检测和图像识别等计算机视觉任务的算法和模型。

2. 模型性能评估：作为一个广泛使用的基准测试数据集，ImageNet可用于评估不同模型在图像分类任务上的性能。通过在ImageNet上进行比较，可以更准确地评估和比较不同模型之间的优劣，并推动模型的改进和发展。

3. 深度学习教育：ImageNet的广泛使用也使得它成为深度学习教育中重要的资源之一。许多教育机构和在线课程使用ImageNet作为实践项目，帮助学生理解和应用深度学习算法，并培养他们在计算机视觉领域的技能。

2）COCO（Microsoft Common Objects in Context）

COCO数据集是一个大型的、丰富的物体检测、分割和字幕数据集。它由微软于2014年出资标注，旨在推动计算机视觉领域在复杂场景下的理解和分析能力。COCO数据集包含超过33万张图片，其中超过20万张图片有详细的标注信息，涵盖了91类目标。

1. 目标检测和图像分割：COCO数据集主要用于评估目标检测和图像分割等任务的性能。它提供了丰富的标注信息，包括目标的边界框、分割掩码等，使得研究人员能够更准确地评估模型在这些任务上的表现。

2. 评估标准IOU指标：目标检测和图像分割的评估标准主要基于IOU（Intersection over Union）指标。IOU表示预测框或分割掩码与真实框或掩码之间的重叠程度，是评估模型性能的重要指标之一。